

# ESPECIFICACIÓN TÉCNICA DE SOFTWARE

*Motor Soberano de Liquidaciones y Auditoría de Nómina Escénica (M-LANE)*

## 1. Resumen Ejecutivo de la Arquitectura

M-LANE es un microservicio de backend de alta criticidad diseñado bajo los principios de **Soberanía de Datos (Data Sovereignty)** y **Costo Operacional Cero (\$0 USD en APIs externas)**. El sistema automatiza el ciclo de vida financiero de las producciones teatrales mediante la ingesta de documentos no estructurados (contratos y reportes de taquilla) transformándolos en registros transaccionales relacionales y vectoriales.

### Flujo de Datos del Pipeline de IA Local:

[PDF Contrato / Taquilla] → **FastAPI Backend** → Inferencia Estructurada (Llama 3.1 8B vía Ollama) → Embeddings Locales (BGE-M3) → Almacenamiento e Indexación (PGVector en PostgreSQL 16) → Optimización y Filtrado (BGE-Reranker-Large).

## 2. Stack Tecnológico e Infraestructura

- **Core API:** FastAPI (Python 3.11+) con ejecución asíncrona (`async/await`) y tipado estricto mediante Pydantic v2.
- **Orquestación de Contexto:** LangGraph / LlamaIndex para la gestión de flujos de agentes deterministas y cíclicos.
- **Motor de Inferencia (LLM):** Meta Llama 3.1 (8B Instruct) ejecutado localmente mediante Ollama o vLLM.
- **Procesamiento Vectorial y Reranking:**
  - *Embeddings:* **BAAI/bge-m3** con soporte nativo y comprensión semántica profunda para jerga legal/contable en español colombiano.
  - *Re-ranking:* **BAAI/bge-reranker-large** para mitigar alucinaciones y optimizar la ventana de contexto del LLM.
- **Capa de Datos:** PostgreSQL 16 con la extensión nativa de código abierto pgvector.

## 3. Endpoints Críticos y Pipelines de IA

### A. POST /api/v1/ai/extract-contract

Recibe el texto extraído del contrato legal por prestación de servicios o bolo. Utiliza el parámetro `format` de Ollama (Structured Outputs) inyectando un esquema JSON generado dinámicamente por Pydantic. Previene errores de parseo en el backend al forzar al LLM local a responder únicamente con tipos de datos primitivos válidos.

## B. POST /api/v1/ai/audit-query (Pipeline RAG Avanzado)

1. **Retrieval:** La consulta del usuario se convierte a vector con BGE-M3. Se ejecuta una consulta de similitud de coseno en PostgreSQL mediante operadores indexados con HNSW:

$$\text{Similitud Coseno} = (A \cdot B) / (\|A\| \|B\|)$$

2. **Reranking:** Los top 15 documentos recuperados por similitud semántica se envían al BGE-Reranker junto con la pregunta original. El modelo devuelve un score de relevancia real. Se descartan los documentos con score menor a 0.7.
3. **Generation:** El LLM recibe únicamente los 3 fragmentos de mayor impacto, reduciendo el consumo de memoria RAM y garantizando respuestas financieras exactas libres de alucinación.

---

# PROPUESTA COMERCIAL Y DE NEGOCIO

*Sistema Inteligente de Gestión de Pagos para Artes Escénicas*

## El Problema del Productor Teatral

Cada cierre de temporada o de función se convierte en una pesadilla de hojas de Excel. Calcular cuánto le corresponde a cada actor que cobra por porcentaje, restar las retenciones de ley vigentes en Colombia, verificar quién asistió y responder a los reclamos de "¿Por qué mi pago fue menor este mes?" consume horas de trabajo valiosas que deberían estar invertidas en la excelencia creativa sobre el escenario.

## La Solución: Gestión Inteligente y Privada

Nuestra plataforma automatiza el flujo financiero de su teatro desde el día en que firma al elenco hasta que se realiza la última transferencia bancaria. Lo mejor de todo: **el sistema funciona dentro de sus propios servidores**. Sus contratos, datos de taquilla e identificaciones de los artistas nunca se enviarán a servidores extranjeros ni a empresas de IA de terceros. Su privacidad es absoluta.

## Características Principales del Sistema

| Funcionalidad                   | Beneficio para el Teatro / Productora                                                                                                                                      |
|---------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Lectura Automática de Contratos | Suba el contrato digital de cualquier actor. La IA comprende las cláusulas (pagos fijos, porcentajes o garantías mínimas) y configura las reglas financieras de inmediato. |
| Cierre de Taquilla en Segundos  | Cargue el reporte de ventas de su tiquetería (Tuboleta, eTicket, etc.). El sistema calcula el dinero neto disponible, resta impuestos y gestiona la dispersión exacta.     |
| Asistente Virtual de Auditoría  | Un chat integrado responde dudas de liquidación basándose en los contratos reales. Resuelve preguntas complejas del equipo contable o del elenco en tiempo real.           |

## Beneficios Estratégicos

- **Ahorro de Tiempo Sostenible:** Reduzca el tiempo de gestión de nómina variable de días a minutos.
- **Transparencia y Confianza:** Entregue desgloses de pago claros, detallados y profesionales a sus artistas, mejorando el clima laboral de la compañía.

- **Costo de Operación Cero (\$0):** Al utilizar modelos de Inteligencia Artificial de código abierto (Open-Source), usted no paga costosas suscripciones ni tarifas por token consumido. El software es de su propiedad intelectual y operativa.